

Organización de datos - TP 1

Grupo 10 - Checkpoint 4:

Se entrenó un modelo de redes neuronales:

Arquitectura e hiperparámetros utilizados:

En el proceso de entrenamiento de nuestro modelo, hemos empleado una arquitectura compuesta por dos capas intermedias. La primera capa tiene 64 unidades, mientras que la segunda cuenta con 32 unidades. Estas capas han sido activadas utilizando la función de activación ReLU, que brinda una respuesta no lineal a las entradas.

Para evitar el sobreajuste del modelo, hemos implementado la técnica de Dropout, que consiste en desactivar aleatoriamente un porcentaje de las unidades de la red durante el entrenamiento. Hemos aplicado una tasa de Dropout del 0.18 en la primera capa y del 0.15 en la segunda capa. La capa de salida del modelo utiliza la función de activación Sigmoid, que nos permite estimar la probabilidad de pertenecer a una de las dos clases en la tarea de clasificación binaria.

Durante el entrenamiento, hemos utilizado un tamaño de lote (batch size) de 64. Como optimizador, hemos utilizado el algoritmo Adam.

Además, hemos aplicado la técnica de regularización (Early Stopping) con una paciencia (patience) de 5. Esto significa que si el rendimiento en el conjunto de validación no mejora durante 5 épocas consecutivas, se detiene el entrenamiento para evitar un sobreajuste del modelo.

Resultados obtenidos y conclusiones:

El modelo entrenado con esta arquitectura y configuración de hiperparámetros ha demostrado un buen desempeño en la tarea de clasificación binaria. Utilizando la métrica F1 para evaluar su rendimiento, hemos obtenido un valor de 0.8598 en el conjunto de validación.

La selección de la arquitectura y los hiperparámetros fue importante para lograr estos resultados. Se probó con distintas cantidades de capas intermedias, cantidad de unidades y distintos optimizadores. Esta combinación específica ha demostrado optimizar el valor de F1, manteniendo un equilibrio cercano entre las métricas de entrenamiento y validación.

En resumen, el modelo entrenado ha mostrado ser efectivo en la clasificación binaria, brindando resultados buenos en la competencia también y validando la elección de los parámetros utilizados.